

МОСКОВСКИЙ ФИЗИКО-ТЕХНИЧЕСКИЙ ИНСТИТУТ
(НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ)

Кафедра общей физики

Вопрос по выбору к экзамену по оптике (4 семестр)

Численное моделирование и
восстановление изображений при
прохождении через
случайно-неоднородные среды с
использованием методов глубокого
обучения

Выполнил:

Студент группы Б04-401
Карпунин Егор Сергеевич

Долгопрудный, 2026

Содержание

1	Введение	2
2	Физическая модель и математический аппарат	3
2.1	Метод углового спектра (Angular Spectrum Method)	3
2.2	Модель случайного фазового экрана	5
3	Методы восстановления изображений	7
3.1	Нейросетевой подход на базе архитектуры U-Net	7
3.2	Классический подход: Эффект памяти и алгоритм Фиенапа (НЮ)	7
4	Параметры численного эксперимента	8
5	Результаты численного моделирования и анализа	9
5.1	Визуализация прямого физического процесса	9
5.2	Восстановление изображений нейросетью U-Net и аналитическим способом	10
5.3	Исследование устойчивости модели к шуму детектора	11
5.4	Сравнительный анализ с итерационным методом Фиенап	12
5.5	Обобщающая способность нейросети (Generalization Test)	12
6	Обсуждение физических результатов и ограничений	13
7	Заключение	13
8	*Дополнительные рассуждения	16

1 Введение

При прохождении когерентного светового излучения сквозь сильно рассеивающую или случайно-неоднородную среду (например, матовое стекло, биологические ткани, аэрозоли) волновой фронт претерпевает многократные случайные искажения. В результате интерференции деформированных парциальных волн в плоскости регистрации наблюдается пространственно-неоднородная картина интенсивности — спекл-поле. Напрямую зарегистрировать изображение объекта с помощью классических оптических систем (линз) в этом случае невозможно, так как фазовая информация теряется при регистрации интенсивности датчиком ($I \propto |E|^2$), а пространственные частоты оказываются квазислучайным образом перемешаны.

Данная проблема известна в оптике как задача восстановления изображений сквозь рассеивающие среды. Исторически для её решения применялись методы голографии, адаптивной оптики и корреляционной месс-оптики (основанной на эффекте оптической памяти). Однако традиционные итеративные алгоритмы восстановления фазы чувствительны к шумам детектора и требуют высокой степени симметрии от исследуемого объекта.

В данной работе исследуется альтернативный подход — применение искусственных нейронных сетей класса U-Net для аппроксимации обратного нелинейного оператора рассеяния. В рамках работы реализована физически обоснованная численная модель распространения волновых фронтов через тонкий фазовый экран методом углового спектра, сгенерирован синтетический датасет на основе базы данных MNIST, обучена нейросетевая модель в среде PyTorch, и проведено её сравнение с классическим итеративным алгоритмом восстановления фазы Фиенапа (Hybrid Input-Output, HIO).




Рис. 1: Схема установки

2 Физическая модель и математический аппарат

2.1 Метод углового спектра (Angular Spectrum Method)

Вся наша работа посвящена симуляции: у нас есть объект (цифра), свет от него летит к матовому стеклу, а потом к камере. Чтобы компьютер мог это посчитать, нам нужен строгий и быстрый математический закон, который умеет делать ровно одну вещь: взять световое поле в плоскости A и рассчитать, каким оно станет в плоскости B , пролетев расстояние d .

0. База

В основе Фурье-оптики лежит математический аппарат преобразования Фурье. Рассмотрим функцию $f(x)$, описывающую некоторое пространственное распределение (например, амплитуду электрического поля):

- Периодические функции (Ряд Фурье):

Если функция $f(x)$ является периодической с пространственным периодом L , её можно представить в виде бесконечной суммы комплексных экспонент (гармоник) согласно теореме Фурье:

$$f(x) = \sum_{n=-\infty}^{+\infty} C_n e^{i\Omega_n x} \quad (1)$$

где C_n — комплексные коэффициенты разложения, вычисляемые по формуле:

$$C_n = \frac{1}{L} \int_{-L/2}^{L/2} f(x) e^{-i\Omega_n x} dx \quad (2)$$

Здесь величина Ω_n имеет смысл пространственной частоты и определяется как:

$$\Omega_n = n\Omega_0 = n \cdot \frac{2\pi}{L} \quad (3)$$

где $\Omega_0 = \frac{2\pi}{L}$ — основная пространственная частота решетки.

- Непериодические функции (Интеграл Фурье):

Если функция $f(x)$ не является периодической, её разложение переходит в непрерывный спектр и описывается интегралом Фурье:

$$f(x) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} C(\Omega) e^{i\Omega x} d\Omega \quad (4)$$

где спектральная плотность (или пространственный Фурье-спектр) $C(\Omega)$ определяется через прямое преобразование Фурье:

$$C(\Omega) = \int_{-\infty}^{+\infty} f(x) e^{-i\Omega x} dx \quad (5)$$

Рассмотрим плоскую монохроматическую световую волну, распространяющуюся в плоскости (x, y, z) . Полное выражение для напряженности электрического поля имеет вид:

$$E(x, y, z, t) = E_0 e^{-i(\omega t - \vec{k} \cdot \vec{r})} = E_0 e^{i\vec{k} \cdot \vec{r}} e^{-i\omega t} = A e^{-i\omega t} \quad (6)$$

где ω — временная частота световых колебаний, а $\vec{k}$ — волновой вектор и A — комплексная амплитуда. Тогда опустим временную составляющую, так как глаз — квадратичный детектор, засекающий интенсивность света, то

$$I \propto \langle |E(t)|^2 \rangle = E(t) \cdot E^*(t) = (Ae^{-i\omega t}) \cdot (A^*e^{i\omega t}) = AA^* \cdot e^{-i\omega t + i\omega t} = |A|^2$$

Определим комплексную амплитуду поля $A(\vec{r})$, опустив временную зависимость $e^{-i\omega t}$. Для удобства последующего сопоставления с формулами Фурье (выбора знаков) запишем:

$$A(x, y, z) = A_0 e^{i\vec{k} \cdot \vec{r}} \quad (7)$$

Пусть волновой вектор $\vec{k}$ образует с осями x и y углы α и β . Тогда проекции вектора равны:

$$k_x = k \cos \alpha, \quad k_y = k \cos \beta, \quad k_z = \sqrt{k^2 - k_x^2 - k_y^2}, \quad \text{где } k = |\vec{k}| = \frac{2\pi}{\lambda} \quad (8)$$

Расписав комплексную амплитуду плоской волны на входной плоскости $z = 0$, мы замечаем, что пространственная фаза принимает канонический вид экспоненты Фурье:

$$A(x, y, z = 0) = A_0 e^{i(k_x x + k_y y)} \quad (9)$$

Фундаментальный вывод: Отдельная пространственная гармоника из интеграла Фурье физически эквивалентна одной плоской монохроматической волне, распространяющейся в пространстве под строго определенными углами (α, β) .

1. **Разложение на веер плоских волн (Прямое ПФ)** Пусть в плоскости $z = 0$ нам известно сложное распределение поля $A(x, y, 0)$ (свет от цифры). Мы берем от него прямое преобразование Фурье и находим угловой спектр $A(k_x, k_y, 0)$, то есть определяем “вес” и начальную фазу каждой элементарной плоской волны в общем пучке:

$$A(k_x, k_y, k_z = 0) = \iint_{-\infty}^{\infty} A(x, y, 0) e^{-i(k_x x + k_y y)} dx dy \quad (10)$$

$$\text{где } k_x = k \cos \alpha(\Omega), \quad k_y = k \cos \beta(\Omega), \quad k_z = \sqrt{k^2 - k_x^2 - k_y^2} \quad (11)$$

2. **Шаг 2: Симуляция “перелета” (Линейная фильтрация)** Каждая плоская волна летит до плоскости $z = d$ независимо. При этом она накапливает фазу за счет продольной компоненты волнового вектора k_z :

$$k_z = \sqrt{k^2 - k_x^2 - k_y^2} \quad (12)$$

Эволюция спектра описывается простым умножением на передаточную функцию свободного пространства $H(k_x, k_y, d)$:

$$A(k_x, k_y, d) = A(k_x, k_y, 0) \cdot H(k_x, k_y, d) = A(k_x, k_y, 0) \cdot e^{id\sqrt{k^2 - k_x^2 - k_y^2}} \quad (13)$$

* Физический смысл передаточной функции H при $k_x^2 + k_y^2 > k^2$ (Эванесцентные волны): Продольный волновой вектор k_z связан с поперечными пространственными частотами

k_x, k_y дисперсионным соотношением: $k_z = \sqrt{k^2 - (k_x^2 + k_y^2)}$. Если пространственные частоты объекта настолько высоки (мелкие субволновые детали, резкие границы пикселей), что $k_x^2 + k_y^2 > k^2$, выражение под корнем становится отрицательным. Вынося мнимую единицу, получаем:

$$k_z = i\sqrt{(k_x^2 + k_y^2) - k^2} = i\alpha, \text{ где } \alpha > 0$$

Подставляя это значение в передаточную функцию (пропагатор) свободного пространства, находим:

$$H(k_x, k_y, d) = e^{i \cdot d \cdot (i\alpha)} = e^{-d\alpha}$$

Физический смысл: Такие компоненты поля представляют собой эванесцентные (затухающие) волны. В отличие от бегущих волн, которые совершают гармонический фазовый набег и переносят энергию, эванесцентные волны экспоненциально затухают по амплитуде вдоль оси распространения z . Они локализованы в ближней зоне у поверхности объекта (на расстояниях порядка нескольких длин волн λ) и не улетают в дальнее поле. Физически они несут в себе информацию о субволновой структуре объекта — деталях, которые меньше длины волны света.

3. **Шаг 3: Сборка поля в плоскости Б (Обратное ПФ)** Зная спектр прилетевших волн, мы складываем (интегрируем) их обратно, получая результирующее комплексное поле в целевой плоскости:

$$A(x, y, z = d) = \frac{1}{4\pi^2} \iint_{-\infty}^{\infty} A(k_x, k_y, d) e^{i(k_x x + k_y y)} dk_x dk_y \quad (14)$$

2.2 Модель случайного фазового экрана

Сильно рассеивающая среда в первом приближении моделируется как тонкий случайный фазовый экран, который мгновенно модулирует фазу проходящей через него волны, оставляя амплитуду неизменной. Модуляция описывается комплексным коэффициентом пропускания:

$$T_{scr}(x, y) = \exp(i\phi(x, y)) \quad (15)$$

Для реалистичного моделирования физического рассеивателя (например, матового стекла) случайная фаза $\phi(x, y)$ представляется как стационарное гауссовское случайное поле с нулевым средним, дисперсией σ_ϕ^2 (задающей силу рассеяния) и гауссовой функцией пространственной корреляции:

$$B_\phi(\Delta x, \Delta y) = \langle \phi(x, y) \phi(x + \Delta x, y + \Delta y) \rangle = \sigma_\phi^2 \exp\left(-\frac{\Delta x^2 + \Delta y^2}{2\rho_c^2}\right) \quad (16)$$

где ρ_c — радиус корреляции неоднородностей рассеивателя.

Тогда так как компьютер умеет генерировать только абсолютно независимый белый шум (где пиксели вообще не связаны друг с другом), то чтобы превратить независимый белый шум в физичный рельеф матового стекла, мы должны перевести требования функции B_ϕ на язык частот. Здесь и работает теорема Винера — Хинчина: преобразование Фурье от функции автокорреляции случайного процесса B_ϕ равно его энергетическому спектру (спектральной плотности мощности) $S_\phi(\omega_x, \omega_y)$.

$$\mathcal{F}\{B_\phi(\Delta x, \Delta y)\} = S_\phi(\omega_x, \omega_y)$$

Вывод итоговой формулы фазы:

- **Находим спектр мощности стекла**

Берем двумерное преобразование Фурье от нашей гауссовой функции корреляции B_ϕ (в лекционных частотах ω_x, ω_y):

$$S_\phi(\omega_x, \omega_y) = \iint_{-\infty}^{\infty} \left[\sigma_\phi^2 \exp\left(-\frac{\Delta x^2 + \Delta y^2}{2\rho_c^2}\right) \right] e^{-i(\omega_x \Delta x + \omega_y \Delta y)} d\Delta x d\Delta y$$

Поскольку Фурье-образ от гауссианы — это тоже гауссиана, интеграл берется аналитически:

$$S_\phi(\omega_x, \omega_y) = 2\pi \sigma_\phi^2 \rho_c^2 \exp\left(-\frac{\rho_c^2(\omega_x^2 + \omega_y^2)}{2}\right)$$

Так B_ϕ превратилась в функцию S_ϕ , которая показывает, сколько энергии матовое стекло передает на каждой пространственной частоте.

- **Как это применяется для генерации фазы** Чтобы получить итоговое случайное поле фазы $\phi(x, y)$, программа выполняет следующую операцию:

1. Генерирует матрицу белого шума $W(x, y)$ (с абсолютно плоским спектром).
2. Берет от нее прямое преобразование Фурье: $\mathcal{F}\{W\}$.
3. Умножает спектр шума на корень из спектра мощности нашего стекла $\sqrt{S_\phi}$.
4. Берет обратное преобразование Фурье, чтобы вернуться в реальные координаты.

Итоговая явная формула генерации случайной фазы, в которой конструктивно сидит B_ϕ , выглядит так:

$$\phi(x, y) = \text{Normalize} \left(\mathcal{F}^{-1} \left\{ \mathcal{F}\{W(x, y)\} \cdot \sqrt{S_\phi(\omega_x, \omega_y)} \right\} \right)$$

Как итог, экспериментально на матрице ПЗС/КМОП-детектора регистрируется только распределение интенсивности рассеянного поля в плоскости наблюдения $z = d_2$ (свет проходит d_1 - расстояние от транспаранта до матового стекла, после чего получается прирост по фазе, исходя из формул выше, далее проходит d_2 - расстояние от матового стекла до квадратичного детектора):

$$I_{cam}(x, y) = |U(x, y, d_1 + d_2)|^2 + \eta(x, y) \quad (17)$$

где $\eta(x, y)$ — аддитивный аппаратный шум детектора (связанный с нагревом, шумом электроники и тп).

3 Методы восстановления изображений

3.1 Нейросетевой подход на базе архитектуры U-Net

Для решения задачи восстановления $\hat{I}_{obj} \approx I_{obj}$ по наблюдаемому спеклу I_{cam} применяется глубокая сверточная нейросеть архитектуры U-Net. Её структура состоит из сжимающего пути (энкодера) для извлечения пространственных признаков разного масштаба и симметричного расширяющего пути (декодера) для детальной локализации и восстановления структуры объекта.

Важнейшим элементом архитектуры являются *skip-connections* (сквозные связи), которые передают высокочастотные карты признаков из энкодера напрямую в декодер, минуя «бутылочное горлышко» сети. Это позволяет сохранять информацию о границах и мелких деталях изображения, которая иначе теряется при операциях понижения размерности (Max Pooling).

Для обучения сети используется взвешенная функция потерь, комбинирующая среднеквадратичную ошибку (MSE) и индекс структурного сходства (SSIM):

$$\mathcal{L}(I, \hat{I}) = \alpha \cdot \text{MSE}(I, \hat{I}) + (1 - \alpha) \cdot (1 - \text{SSIM}(I, \hat{I})) \quad (18)$$

где коэффициент $\alpha \in [0, 1]$ настраивается экспериментально для баланса между попиксельной точностью и резкостью границ.

3.2 Классический подход: Эффект памяти и алгоритм Фиенапа (НЮ)

В качестве классического физического бейзлайна в работе рассматривается метод восстановления изображений, основанный на концепции оптического эффекта памяти (Optical Memory Effect, ОМЕ). Физическая суть эффекта заключается в том, что в пределах некоторого критического угла наклона падающего когерентного пучка $\Delta\theta < \theta_{ME} \approx \frac{\lambda}{2\pi L}$ (где L — толщина рассеивающей среды) волновые пути внутри среды перестраиваются незначительно. Как следствие, спекл-картина в плоскости регистрации смещается как единое целое пространственно-инвариантным образом, сохраняя свою внутреннюю интерференционную структуру.

Из пространственной инвариантности оператора рассеяния следует, что зарегистрированное распределение интенсивности спекл-поля $I_{cam}(x, y)$ можно представить в виде свертки интенсивности исходного объекта $I_{obj}(x, y)$ и случайной функции размытия точки (спекл-отклика точечного источника) $S(x, y)$:

$$I_{cam}(x, y) = I_{obj}(x, y) * S(x, y)$$

Применив к обеим частям равенства операцию пространственной автокорреляции (определяющей меру самоподобия функции при её пространственном сдвиге), получаем:

$$A_{I_{cam}}(\Delta x, \Delta y) \approx A_{I_{obj}}(\Delta x, \Delta y) * A_S(\Delta x, \Delta y) + \text{const}$$

где $A_{I_{cam}}$ и $A_{I_{obj}}$ — функции автокорреляции спекл-поля и объекта соответственно, а A_S — автокорреляция спекла от точечного источника. Поскольку для полностью развитого спекл-поля функция A_S представляет собой узкий дельта-образный пик на однородном фоне, её вклад сводится к тождественному преобразованию. Таким образом, автокорреляция зарегистрированного спекла математически эквивалентна автокорреляции скрытого объекта.

Согласно теореме Винера — Хинчина, Фурье-преобразование функции автокорреляции функции равно квадрату модуля её пространственного спектра (спектральной плотности мощности):

$$\mathcal{F}\{A_{I_{obj}}\} = |\mathcal{F}\{I_{obj}\}|^2$$

Это позволяет напрямую извлечь амплитудный (модульный) спектр скрытого объекта из экспериментально измеряемой интенсивности спекла:

$$|\mathcal{F}\{I_{obj}\}| = \sqrt{\mathcal{F}\{A_{I_{cam}}\}}$$

Поскольку фазовая информация спектра при квадратичном детектировании камерой безвозвратно теряется, задача реконструкции переходит в класс некорректных обратных задач и формулируется как фазовая проблема (Phase Retrieval). Для её численного решения применяется итерационный алгоритм гибридного ввода-вывода Фиенапа (Hybrid Input-Output, НИО).

Алгоритм осуществляет последовательные проекции поля между частотной областью (где на каждой итерации принудительно задается экспериментальный модуль спектра $|\mathcal{F}\{I_{obj}\}|$) и реальным пространством, где накладываются априорные физические ограничения: финитность (компактность геометрического носителя объекта, маска support) и неотрицательность пространственной интенсивности ($I_{obj} \geq 0$). За счет введения шага обратной связи с коэффициентом β , алгоритм минимизирует целевой функционал ошибки фазы, успешно выходя из локальных минимумов стагнации.

4 Параметры численного эксперимента

Для генерации обучающей и тестовой выборки были зафиксированы следующие физические и численные параметры системы:

- **Длина волны излучения:** $\lambda = 532$ нм.
- **Размер сетки моделирования:** $N \times N = 128 \times 128$ пикселей.
- **Физический размер пикселя расчетной сетки:** $\Delta x = \Delta y = 4.0$ мкм.
- **Расстояние от объекта до рассеивателя:** $d_1 = 1$ мм.
- **Расстояние от рассеивателя до камеры:** $d_2 = 8$ мм.
- **Параметры рассеивателя:** радиус корреляции фазового экрана $\rho_c = 12$ мкм, стандартное отклонение фазы $\sigma_\phi = 1.5\pi$ рад (режим сильного фазового рассеяния).
- **Набор данных:** База данных рукописных цифр MNIST (28×28 пикселей), интерполированная до размера расчетной сетки. Объем обучающей выборки: 8000 пар, тестовой: 2000 пар.

Численная и физическая модель проекта строго ограничена следующими безразмерными критериями:

- Geometric/Diffraction regime: Число Френеля системы составляет $N_F \approx 15.4$, что относит схему к ближней зоне дифракции Френеля и обуславливает применение метода углового спектра вместо приближения дальней зоны Фраунгофера. Исходный вид формулы:

$$N_F = \frac{a^2}{\lambda d}$$

где a — характерный радиус освещенной апертуры (в твоём случае — размер цифры), λ — длина волны (532 нм), d — расстояние пролета волны (d_1 или d_2).

- Scalar and Forward scattering limits: Шаг сетки и радиус корреляции рассеивателя много больше длины волны ($\Delta x, \rho_c \gg \lambda$), что обосновывает применение скалярной теории Гельмгольца и гарантирует режим малоуглового рассеяния вперед.
- Sampling constraint: Нижняя граница дистанции d_2 жестко ограничена критерием Найквиста, она накладывается теоремой Котельникова на шаг нашей расчетной сетки Δx . Чтобы камера смогла зафиксировать спекл-картину, физический размер одного спекл-зерна $\delta_s \approx \frac{\lambda d_2}{D}$ обязан укладываться минимум в два пикселя матрицы:

$$\Delta x \leq \frac{\delta_s}{2}$$

В противном случае высокочастотная фазовая информация необратимо теряется при усреднении апертурой пикселя

Выбранный в работе метод углового спектра (ASM) математически инвариантен к числу Френеля, поскольку в его основе лежит строгое решение уравнения Гельмгольца без использования Тейлоровских приближений ближней или дальней зоны. Наш программный движок `propagateasm(, )d2`. Однако на практике диапазон моделирования ограничен параметрами дискретизации: при критическом удалении в зону Фраунгофера шаг фазы пропагатора нарушает критерий Найквиста, вызывая алиасинг сетки, а при критическом приближении в геометрическую зону размер спеклов падает ниже физического размера пикселя Δx , вызывая пространственное апертурное усреднение

Сразу предложу решение некоторых вопросов:

1. Как убрать алиасинг при удалении камеры? Ограничить полосу пропускания частот ($H = \exp(1j \cdot d_2 \cdot k_z)$) в ASM (Band-Limited ASM) или перейти от схемы двух FFT к схеме одного FFT (интеграл Фраунгофера).

2. Как убрать потерю контраста при приближении камеры? Численно уменьшать шаг сетки dx через апсемплинг матриц, либо аппаратно ставить увеличивающий микрообъектив перед матрицей детектора.

5 Результаты численного моделирования и анализа

5.1 Визуализация прямого физического процесса

На рисунке 2 представлены результаты прямого моделирования распространения света: исходное изображение амплитудного объекта (цифра из MNIST), распределение фазы случайного экрана и зарегистрированная на камере спекл-картина.



Рис. 2: Этапы прямого численного моделирования рассеяния света: $d1=1\text{мм}$, $d2=2\text{мм}$



Рис. 3: Этапы прямого численного моделирования рассеяния света: $d1=0\text{мм}$, $d2=8\text{мм}$

5.2 Восстановление изображений нейросетью U-Net и аналитическим способом

Сеть U-Net обучалась в течение 15 эпох с использованием оптимизатора Adam ($lr = 10^{-4}$). График обучения представлен на рис. 4.




Рис. 4: Зависимость функции потерь от эпохи обучения (Train/Val Loss)

Аналитический способ состоял из 500 итераций на фото и не требовал обучения, однако было необходимо знать зависимость фазы от координат для матового стекла.

На рисунке 5 приведен пример работы 2ух алгоритмов




Рис. 5: Пример работы

5.3 Исследование устойчивости модели к шуму детектора

Для оценки физической применимости метода была исследована устойчивость алгоритма к шумам ПЗС-матрицы. В тестовые спекл-картины вносился аддитивный белый гауссовский шум с различным отношением сигнал/шум (SNR). Зависимость качества восстановления (по метрике SSIM) от уровня шума приведена на рис. 6.




Рис. 6: Зависимость метрики SSIM восстановленных объектов от величины SNR на входе




Рис. 7: SNR = 100




Рис. 8: $SNR = 1$

$$SNR = \frac{\text{Мощность полезного сигнала (света)}}{\text{Мощность шума матрицы}}$$

Рис. 9: SNR

5.4 Сравнительный анализ с итерационным методом Фиенапа

В таблице 2 приведено количественное сравнение работы нейросетевого подхода и классического алгоритма Фиенапа (НЮ) по точности и вычислительным затратам.

Таблица 1: Сравнение нейросетевого метода и алгоритма Фиенапа на $d1 = 0\text{мм}$, $d2 = 8\text{мм}$

Метод восстановления	Средний SSIM	Средний MSE
Алгоритм Фиенапа (НЮ, 500 ит.)	0.1175	0.08912
Нейросеть U-Net (Inference)	0.8431	0.01716

Таблица 2: Сравнение нейросетевого метода и алгоритма Фиенапа на $d1 = 1\text{мм}$, $d2 = 8\text{мм}$

Метод восстановления	Средний SSIM	Средний MSE
Алгоритм Фиенапа (НЮ, 500 ит.)	0.1202	0.08824
Нейросеть U-Net (Inference)	0.8481	0.01715

5.5 Обобщающая способность нейросети (Generalization Test)

Важным этапом исследования стала проверка обобщающей способности нейросети. На вход модели, обученной исключительно на цифрах MNIST, были поданы спекл-картины, полученные от геометрических фигур (круг, треугольник). Результаты представлены на рис. 10.




Рис. 10: Попытка восстановления спеклов нетипичных объектов (геометрических фигур) сетью, обученной на цифрах, а также аналитическим подходом

6 Обсуждение физических результатов и ограничений

Анализ полученных результатов позволяет выявить ключевые достоинства и физические ограничения обоих подходов:

1. **Физическая привязка к среде (декорреляция):** Нейросеть настраивает свои веса под конкретную конфигурацию фазового экрана $\phi(x, y)$. При смещении рассеивателя на расстояние, превышающее радиус корреляции ρ_c , матрица передачи среды T полностью изменяется. Спекл декоррелирует, и обученная нейросеть теряет способность к восстановлению. Классический метод автокорреляции более инвариантен к малым сдвигам благодаря сохранению эффекта памяти.
2. **Фазовая проблема и симметрия:** Метод автокорреляции принципиально не позволяет однозначно восстановить асимметричные объекты из-за потери фазового спектра, приводя к возникновению «двойников» (twin-image). Модель U-Net, выучив априорное распределение объектов (image prior) в процессе обучения, успешно решает эту неоднозначность.
3. **Вычислительная сложность:** Время инференса обученной нейросети составляет единицы миллисекунд (на GPU), что делает её применимой для систем реального времени (при этом стоит учесть, что необходимо будет потратить в нашем случае около 5 минут на предварительное обучение), в то время как алгоритм НЮ требует сотен итераций преобразования Фурье для каждого отдельного кадра. Однако в рамках нашей задачи разница не ощутима.

7 Заключение

В данной работе было проведено детальное численное исследование распространения света через случайно-неоднородные среды и его последующего восстановления. С помощью волнового метода углового спектра была смоделирована реалистичная оптическая система регистрации спекл-картин.

Была успешно реализована сверточная нейросеть U-Net на платформе PyTorch. В результате сравнительного анализа было продемонстрировано, что нейросетевой подход превосходит классический итерационный алгоритм Фиенэпа по качеству восстановления асимметричных контрастных объектов и по скорости работы, однако обладает жестким ограничением в виде зависимости от обучающей выборки (класса объектов) и стационарности свойств рассеивающей среды.

Как итог полученные в докладе эксперименты **применимы** в задачах:

- Биомедицинская оптика (Эндоскопия и томография)
Суть: Видение сквозь тонкие слои живых биологических тканей (кожа, стенки сосудов, тонкие хрящи), которые работают как сильные матовые рассеиватели.
Почему здесь: Расстояния микроскопические (миллиметры), излучение лазера когерентно, а структура ткани в рамках одного сеанса сканирования относительно стабильна (стационарна).
- Оптическое шифрование и защита данных (PUF — Физически неклонировуемые функции)
Суть: Матовое стекло используется как «физический ключ». Ты кодируешь секретную картинку в спекл-поле, а нейросеть U-Net обучается работать «декодером» только для этого конкретного стекла.
Почему здесь: Без знания точной конфигурации фазового экрана восстановить информацию математически невозможно, что обеспечивает аппаратную защиту данных.
- Нанооптика и контроль микросхем
Суть: Восстановление геометрии субволновых объектов или дефектов на кремниевых подложках через промежуточные рассеивающие слои.

При этом применение в следующих задачах **не рекомендуется**:

- Макроскопические и атмосферные задачи (Дальнометрия, Лидары, Беспилотники в тумане)
Почему нет: Как мы уже выяснили, на дистанциях в сотни метров и километры при зеленом лазере размер спеклов остается микрометровым. Огромные макропиксели камер беспилотников просто усредняют эти спеклы в однородный серый туман. Информация о фазовых полосках полностью сотрется, и U-Net будет выдавать кашу. Для таких задач используют другие методы (например, времяпролетные камеры ToF или адаптивную лучевую оптику).
- Динамические и быстроменяющиеся среды (Дым, движущийся туман, текущая жидкость)
Почему нет: Нейросеть жестко подстраивает свои веса под конкретный стационарный фазовый экран. Если матовое стекло начнет двигаться или пупырышки на нем будут менять форму каждую миллисекунду (как капли в летящем дыму), нейросеть мгновенно «ослепнет». Ей придется заново собирать датасет и переобучаться под каждую новую микросекунду положения среды.
- Некогерентное освещение (Солнечный свет, обычные светодиоды, вспышки)
Почему нет: Весь метод углового спектра и формирование полосатых спеклов требуют строгой пространственной и временной когерентности. Обычный белый свет не создает интерференционных узоров при рассеянии. На камере получится просто размытое пятно без какой-либо скрытой структуры частот.

Список литературы

- [1] Кириченко Н.А. *Принципы оптики* — Москва, МФТИ, 2016.
- [2] Гавриков А.В. *Цикл консультаций для студентов 2-го курса МФТИ, обучающихся по курсу "Оптика"* — Москва, МФТИ, 2019.
- [3] Гудмен Дж. *Введение в фурье-оптику*. — М.: Мир, 1970.
- [4] Ronneberger O., Fischer P., Brox T. *U-Net: Convolutional Networks for Biomedical Image Segmentation* // Medical Image Computing and Computer-Assisted Intervention (MICCAI). — 2015. — Vol. 9351. — P. 234–241.
- [5] Bertolotti J. et al. *Non-invasive imaging through opaque scattering layers* // Nature. — 2012. — Vol. 491. — P. 232–234.
- [6] Fienup J. R. *Phase retrieval algorithms: a comparison* // Applied Optics. — 1982. — Vol. 21. — No. 15. — P. 2758–2769.

8 *Дополнительные рассуждения

- В исходной бесконтактной геометрии ($d_1 \neq 0$), которая чаще всего и встречается в реальных экспериментах, классическая фазовая проблема становится некорректной и неразрешимой для одиночного кадра, если структура рассеивателя неизвестна заранее. И именно здесь проявляется фундаментальное преимущество глубокого обучения: в то время как физический бейзлайн Фиенапа математически бессилен в бесконтактной схеме без знания профиля стекла, нейросеть U-Net способна неявно выучить статистику и оператор инверсии этого конкретного фазового экрана в процессе обучения на датасете, успешно восстанавливая изображения там, где классическая фурье-оптика пасует
- Для прикладных биологических задач классическое обучение «с учителем» ограничено невозможностью получения Ground Truth внутри живых тканей. Однако эта проблема успешно решается в рамках нашей модели двумя путями. Во-первых, за счет свойства масштабной и статистической инвариантности: сеть, обученная на синтетическом датасете со случайными экранами фиксированного радиуса корреляции ρ_c , учится игнорировать конкретный профиль фазы и извлекать общие признаки объекта. Во-вторых, в экспериментальной практике это реализуется через калибровку на оптических фантомах с программируемыми пространственными модуляторами света (SLM), что позволяет собрать обучающую выборку до начала работы с реальным биообъектом
- Классический Фиенап — это жесткий детерминированный алгоритм. В честной схеме ($d_1 > 0$) он требует абсолютно точного знания микроструктуры рассеивателя $\phi(x, y)$. Если мы не можем сделать попиксельную копию стекла, аналитика полностью ломается. В то время как в данной работе успешно реализован детерминированный режим (обучение на фиксированном фазовом экране, моделирующем стационарный биообъект), теоретический анализ показывает возможность расширения модели. При переходе к обучению на ансамбле случайных фазовых экранов с фиксированными макропараметрами (ρ_c, σ_ϕ), нейросеть переходит от зазубривания конкретной функции рассеяния точки к извлечению статистических инвариантов рассеяния среды. Это открывает перспективу обобщающей способности (generalization over unseen media), что является темой для дальнейших исследований
- Важное замечание про вид спекла: при регенерации стационарного фазового экрана, а в жизни при покупке аналогичного матового стекла, рассмотрим изменение картины $\varphi(x, y)$
 1. На пиксельном уровне (Детерминированно) — разница колоссальная. Если регенерировать белый шум в коде, матрица пупырышек матового стекла (x,y) станет абсолютно другой. Соответственно: Все микроскопические лучи света полетят по новым траекториям. А плоскости камеры фазы волн перераспределятся, и там, где раньше был пик интерференции (яркая полосочка), теперь может оказаться глубокий провал (темнота).

При попытке вычитания одной картинки из другой в лоб ($speckle_1 - speckle_2$), мы получим чистый хаос, а метрика MSE (среднеквадратичная ошибка) между ними будет огромной. Спекл изменится до неузнаваемости попиксельно.

2. На статистическом уровне (Макроскопически) — они будут близнецами. Несмотря на то, что яркие пятнышки поменяются местами, характер картинки останется абсолютно прежним:

- Контраст спекла останется строго равен единице (свойство полностью развитого спекл-поля).
- Средний размер зерна (толщина твоих полосочек) $\delta_s \approx \frac{d_2}{D}$ останется неизменным, потому что длина волны и геометрия системы не менялись.
- Направление полос останется точно таким же. Поскольку объект (цифра «5») не менялся, направления дифракции света на его контурах остались прежними. Твой спекл будет состоять из таких же «шумных полосочек», идущих под теми же углами, просто сам узор внутри этих полосочек «перетряхнется».

Именно поэтому при отсутствии попиксельной копии стекла классический Файнап не будет работать, в то время как нейросеть, базирующаяся на макропризнаках, выдаст хорошие ответы

- При переходе к полностью слепому бесконтактному режиму ($d_1 \neq 0, d_2 \neq 0, \phi$ — неизвестна) обнаруживается фундаментальный предел аналитических методов: классический алгоритм Финапа принципиально неспособен восстановить объект из-за математической недоопределенности задачи (single-shot blind phase retrieval). В то же время нейросетевой подход демонстрирует гибкость: если неизвестная рассеивающая среда стационарна, U-Net успешно аппроксимирует сквозной оператор инверсии системы без явного знания фазовой маски. Однако при динамически меняющейся среде бесконтактная схема становится непреодолимым барьером и для распознавания нейросетями из-за полного разрушения пространственно-инвариантных корреляций поля при предварительной дифракции на расстоянии d_1